

## 教育经历

清华大学 | 电子信息 | 硕士

2025.09 – 2028.06

哈尔滨工业大学 | 精密仪器 | 本科

2020.09 – 2024.06

- 五四表彰优秀学生、两次人民奖学金；大创国家级一等奖。
- 第八届智能车竞赛智能视觉组北部赛区三等奖；第九届光电设计竞赛东北赛区二等奖。

## 端侧 AI 实习与项目

算能科技 | 芯片规划工程师

2026.01 – 2026.05

单目深度模型部署、量化与推理优化

- 在 CV186 Mars3 ( BM1684X、UMA 架构 ) 完成 300M 参数级单目深度模型从 PyTorch/ONNX 到 TPU 运行时的转换、算子适配和性能优化。
- 裁剪 Mask/法线分支，固化位置编码与 Token 长度，将注意力改写为显式  $QK^T$ ；改造归一化与 Resample 模块，在 C++ 侧完成异常值隔离和拼接融合。
- 按节点敏感度设计 FP16/INT8 混合量化；参数量 300M→85M，显存 1.9GB→0.9GB，带宽 30GB/s→5GB/s，在 17W 约束下实现 1080P@30fps。
- 待补充 Profiling/精度结果：端到端延迟 [A]→[B]，p95 延迟 [待填]，峰值内存 [待填]，量化后 Abs Rel/RMSE 变化 [待填]。

vivo | 影像效果工程师

2026.06 – 2026.08

LiveAgent | VLM/DiT 端侧部署与 Kotlin SDK

- 将空间拼贴样例解析、素材理解、自动布局和效果执行架构翻译为 Kotlin，封装移动端 SDK；完成模块接口、数据传递、滤镜/文本/DiT 玩法和端侧功能联调。
- 针对规划中的 VLM “大脑”和 DiT “工具”完成量化部署与推理接口适配，打通“视觉解析—模型调用—布局执行—效果输出—SDK 调用”闭环。
- 待补充端侧结果：模型格式/量化方案 [待填]，单次推理时延 [待填]，峰值内存 [待填]，端到端调用耗时 [待填]。

可靠视觉输入 | 自动化 PQ 分析与参数工具

- 支持 JPEG 对比图与 RAW 图输入，串联样本管理、图像解析、VLM 场景标签、RAG 检索、JSON 参数建议和回归验证，完成自动化调参工具落地。
- 将 VLM 用于天黑、逆光、灯光、人像等场景语义解析，将图像问题映射到可执行的 JSON 参数候选，避免让语言模型直接替代像素级质量评价。
- 待补充工具结果：覆盖 [场景数] 类场景，单轮测试耗时 [A]→[B]，人工调参步骤减少 [待填]。

[完成后启用] LingBot-VLA | VLA 仿真部署与推理优化

[时间]

- 基于 LingBot-VLA 2.0 与 RoboTwin 2.0 搭建 VLA 推理和仿真评测链路，完成模型服务、仿真环境、任务调度、日志和视频结果管理。
- 评估 FP32/BF16、action chunk、视觉输入增强和模型服务并发对显存、延迟及任务成功率的影响；在 [任务数] 个任务上实现 [成功率/时延/显存] 结果。

## 专业技能

- 模型部署：PyTorch、ONNX/ONNX Runtime、算能 TPU/运行时、QNN、MLIR；具备模型导出、计算图改写、算子适配和运行时验证经验。
- 推理优化：FP16/INT8 混合量化、量化敏感度分析、精度回归、算子融合、内存/带宽优化、端侧 Profiling；了解 CPU/NPU 异构执行和 fallback。
- 编译与工程：了解 MLIR lowering、计算图转换和端侧编译流程；C++、Python、Kotlin、Docker、Git，具备移动端 SDK 和批量测试开发经验。
- 视觉与多模态：单目深度、分割、追踪、VLM、RAG、DiT；具备相机成像、ISP/PQ、JPEG/RAW 图像链路实践。
- 其他信息：英语 CET-6；可实习半年以上。